HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

THỰC TẬP CƠ SỞ

Weekly Report

Đề tài: XÂY DỰNG HỆ THỐNG GỢI Ý SẢN PHẨM

Giảng viên	**: Kim Ngọc Bách**
Họ và tên sinh viên	**: Nguyễn Văn Trường**
Mã sinh viên	**: B23DCCN870**
Lớp	**: D23CQCN02-B**
Nhóm	**: 11**

Hà Nội – 2026

Nội dung

I. Tổng quan về Recommender System 3

1. Giới thiệu 3

2. Mục tiêu của Recommender System 3

3. Các mô hình phổ biến của Recommeneder System 4

1. Collaborative Filtering (Lọc cộng tác) 4

2. Content-Based Filtering 4

3. Knowledge-Based Recommender System 4

4. Demographic Recommender System 4

5. Hybrid and Ensemble-Based Recommender System 4

II. Các loại Collaborative Filtering 5

1. Memory-Based Collaborative Filtering 5

1.1 User-Based Collaborative Filtering 5

1.2 Item-Based Collaborative Filtering 5

2. Model-Based Collaborative Filtering 6

III. Matrix Factorization 6

1. Giới thiệu 6

2. Ý tưởng của Matrix Factorization 7

3. Latent Factors (Đặc trưng tiềm ẩn) 7

4. Công thức dự đoán rating 8

5. Hàm mục tiêu (Loss Function) 9

6. Các thuật toán Matrix Factorization phổ biến 9

6.1 SVD (Singular Value Decomposition) 9

6.2 SGD (Stochastic Gradient Descent) 10

6.3 ALS (Alternating Least Squares) 10

V. Tổng kết 13

I. Tổng quan về Recommender System

1. Giới thiệu

Recomender System là một nhánh quan trọng của Trí tuệ nhân tạo (AI) và Machine Learning, có nhiệm vụ dự đoán và đề xuất các sản phẩm, dịch vụ hoặc nội dung phù hợp với sở thích của người dùng.

Hai dạng bài toán cơ bản của hệ thống Recommender System:

- **Prediction version of problem:** dự đoán điểm đánh giá rating mà user có thể cho item. Giả sử dữ liệu huấn luyện có sẵn, cho biết sở thích của người dùng đến với các mặt hàng. Với m users và n items tương ứng với một ma trận m x n không đầy đủ. Các giá trị bị thiếu được dự đoán bằng cách sử dụng mô hình này.
- **Ranking version of problem**: Trên thực tế, không cần thiết phải dự đoán xếp hạng của người dùng đối với các mặt hàng cụ thể để đưa ra đề xuất cho người dùng. Thay vào đó, người bán chỉ cần xếp hạng và đề xuất top-k mặt hàng phù hợp cho một người dùng cụ thể hoặc top-k người dùng tiềm năng cho một mặt hàng. Việc tìm top-k sản phẩm cho người dùng phổ biến hơn vì hệ thống gợi ý thường được thiết kế nhằm phục vụ nhu cầu của người dùng.

2. Mục tiêu của Recommender System

Các mục tiêu phổ biến của hệ thống Recommender System:

- **Relevance (Tính liên quan):**
  Gợi ý các item phù hợp với sở thích của người dùng và có khả năng cao được tiêu thụ (xem, mua, nghe,…). Đây là mục tiêu quan trọng nhất của hệ thống.
- **Novelty (Tính mới lạ):**
  Đề xuất những item mới mà người dùng chưa biết đến, tránh lặp lại các item quá quen thuộc để tăng sự hấp dẫn và trải nghiệm khám phá.
- **Serendipity (Tính bất ngờ):**
  Gợi ý những item bất ngờ nhưng vẫn có khả năng được người dùng yêu thích, giúp khám phá sở thích tiềm ẩn và tạo trải nghiệm thú vị.

- **Diversity (Tính đa dạng):**
  Đảm bảo các item trong danh sách **top-k** khác nhau về nội dung hoặc đặc điểm, tránh quá giống nhau và tăng cơ hội người dùng thích ít nhất một item.

3. Các mô hình phổ biến của Recommeneder System

1. Collaborative Filtering (Lọc cộng tác)

Collaborative Filtering tìm kiếm những người dùng tương tự, và đề xuất những người dùng tương tự thích.

Ý tưởng: phần loại người dùng thành các nhóm có cùng loại và đề xuất cho mỗi người dùng theo sở thích của nhóm đó.

2. Content-Based Filtering

Hệ thống gợi ý các item dựa trên đặc điểm nội dung của item và lịch sử sở thích của người dùng.

Ví dụ: nếu người dùng thích phim hành động, hệ thống sẽ đề xuất các phim có thể loại hoặc nội dung tương tự.

3. Knowledge-Based Recommender System

Hệ thống sử dụng tri thức về sản phẩm và nhu cầu của người dùng để đưa ra gợi ý, thay vì dựa vào dữ liệu đánh giá trước đó.

Ví dụ: Gợi ý nhà, xe, laptop dựa trên yêu cầu của người dùng như giá, cấu hình, mục đích sử dụng.

Phương pháp này thường dùng khi:

- Dữ liệu rating ít
- Item có giá trị lớn và ít được mua

4. Demographic Recommender System

Phương pháp gợi ý dựa trên thông tin nhân khẩu học của người dùng như: tuổi / giới tính / nghề nghiệp

Ví dụ: người dùng trong cùng một nhóm tuổi hoặc nghề nghiệp có thể nhận các gợi ý giống nhau

5. Hybrid and Ensemble-Based Recommender System

Hệ thống kết hợp nhiều phương pháp gợi ý khác nhau để cải thiện độ chính xác và khắc phục nhược điểm của từng phường pháp.

II. Các loại Collaborative Filtering

Collaborative Filtering có thể được chia thành hai nhóm chính:

1. Memory-Based Collaborative Filtering

Phương pháp này sử dụng trực tiếp **ma trận user–item** để tìm kiếm sự tương đồng giữa người dùng hoặc giữa các item.

Memory-Based CF thường được chia thành hai loại:

1.1 User-Based Collaborative Filtering

Phương pháp này tìm **những người dùng có sở thích tương tự nhau**.

Nếu:

- User A giống User B
- User B thích một movie nào đó

→ hệ thống sẽ **gợi ý movie đó cho User A**.

Quy trình cơ bản:

1. Tính độ tương đồng giữa các users
2. Chọn các users giống nhất (neighbors)
3. Dự đoán rating dựa trên rating của các neighbors

Các thước đo similarity thường dùng:

- Cosine Similarity
- Pearson Correlation
- Jaccard Similarity

1.2 Item-Based Collaborative Filtering

Phương pháp này tìm **các item giống nhau**.

Nếu:

- User thích Movie A

- Movie A giống Movie B

→ hệ thống sẽ **gợi ý Movie B cho user**.

Ưu điểm:

- ổn định hơn khi số lượng user lớn
- được sử dụng trong nhiều hệ thống thực tế như Amazon.

2. Model-Based Collaborative Filtering

Phương pháp này sử dụng **machine learning models** để học các mẫu trong dữ liệu.

Thay vì tính similarity trực tiếp, hệ thống sẽ **huấn luyện mô hình dự đoán rating**.

Các thuật toán phổ biến:

- Matrix Factorization
- Singular Value Decomposition (SVD)
- Alternating Least Squares (ALS)

III. Matrix Factorization

1. Giới thiệu

Trong hệ thống gợi ý, dữ liệu thường được biểu diễn dưới dạng **ma trận đánh giá người dùng – sản phẩm (user–item rating matrix)**. Tuy nhiên ma trận này thường **rất thưa (sparse)** vì mỗi người dùng chỉ đánh giá một số ít sản phẩm.

Matrix Factorization giải quyết vấn đề này bằng cách **phân rã ma trận rating** Rthành hai ma trận đặc trưng:

$$R \approx PQ^T$$

Trong đó:

- P: ma trận đặc trưng của **user**
- Q: ma trận đặc trưng của **item**

Mỗi user và mỗi item được biểu diễn bằng một **vector đặc trưng tiềm ẩn (latent factor vector)**.

Rating dự đoán của user $u$cho item iđược tính bằng:

$$\hat{r}_{ui} = p_u^T q_i$$

Trong đó:

- p_u là vector đặc trưng của user u
- q_i là vector đặc trưng của item i

Giá trị này chính là **tích vô hướng giữa hai vector**, biểu thị mức độ phù hợp giữa sở thích của user và đặc điểm của item.

2. Ý tưởng của Matrix Factorization

Matrix Factorization phân rã ma trận rating Rthành hai ma trận nhỏ hơn:

$$R \approx P \times Q$$

Trong đó:

Ký hiệu	Ý nghĩa
R	Ma trận rating (user × item)
P	Ma trận đặc trưng của user
Q	Ma trận đặc trưng của item

Giả sử:

- m users
- n items
- k latent factors

Khi đó:

$$R_{m\times n} \approx P_{m\times k} \times Q_{k\times n}$$

3. Latent Factors (Đặc trưng tiềm ẩn)

Các **latent factors** là những đặc điểm ẩn mô tả sở thích của người dùng và đặc điểm của item.

Ví dụ trong hệ thống gợi ý phim, các latent factors có thể đại diện cho:

- mức độ thích **phim hành động**
- mức độ thích **phim tình cảm**
- mức độ thích **phim khoa học viễn tưởng**

Khi đó một user có thể được biểu diễn như sau:

User	Action	Romance	Sci-Fi
U1	0.9	0.2	0.8

Một bộ phim cũng có vector đặc trưng:

Movie	Action	Romance	Sci-Fi
Matrix	0.8	0.1	0.9

Ý nghĩa của Latent Factors

Latent factors giúp mô hình:

- phát hiện **sở thích tiềm ẩn của người dùng**
- mô tả **đặc điểm ẩn của item**
- giảm chiều dữ liệu của ma trận user–item
- cải thiện khả năng dự đoán rating

Nhờ đó, hệ thống có thể đưa ra **các gợi ý cá nhân hóa chính xác hơn**

4. Công thức dự đoán rating

Rating dự đoán được tính bằng tích vô hướng giữa vector user và vector item:

$$\hat{r}_{ui} = p_u^T q_i$$

Trong đó:

- p_u là vector đặc trưng của user u
- q_i là vector đặc trưng của item i

Kết quả của phép tính này cho biết **mức độ phù hợp giữa user và item**.

5. Hàm mục tiêu (Loss Function)

Mục tiêu của thuật toán là **tối thiểu hóa sai số giữa rating thật và rating dự đoán**.

Hàm loss thường dùng:

$$\sum_{(u,i)\in R} (r_{ui} - \hat{r}_{ui})^2 + \lambda(||\, p_u \,||^2 + ||\, q_i \,||^2)$$

Trong đó:

- r_{ui} là rating thực
- $\hat{r}_{ui}$ là rating dự đoán
- λ là hệ số regularization để tránh overfitting

6. Các thuật toán Matrix Factorization phổ biến

6.1 SVD (Singular Value Decomposition)

SVD là một phương pháp phân rã ma trận trong đại số tuyến tính. Trong hệ thống gợi ý, SVD được sử dụng để phân rã **ma trận User–Item** thành các ma trận đặc trưng tiềm ẩn.

Giả sử ma trận rating:

$$R \approx P \times Q^T$$

Trong đó:

- **R**: ma trận rating của user – item
- **P**: ma trận latent factors của user
- **Q**: ma trận latent factors của item

Sau khi học được các ma trận này, hệ thống có thể **dự đoán rating còn thiếu** bằng cách nhân hai ma trận lại với nhau.

Ưu điểm:

- Nền tảng toán học rõ ràng
- Hiệu quả trong nhiều hệ thống gợi ý

Nhược điểm:

- Khó áp dụng trực tiếp cho ma trận rất lớn và dữ liệu thưa.

6.2 SGD (Stochastic Gradient Descent)

SGD là thuật toán tối ưu hóa được sử dụng rất phổ biến để học các tham số trong Matrix Factorization.

Mục tiêu của SGD là **giảm sai số giữa rating dự đoán và rating thực tế**.

Hàm lỗi thường dùng:

$$L = \sum (r_{ui} - \hat{r}_{ui})^2$$

Trong đó:

- r_{ui}: rating thực tế
- $\hat{r}_{ui}$: rating dự đoán

Thuật toán sẽ:

1. Khởi tạo ngẫu nhiên ma trận **P và Q**
2. Lặp qua các rating đã biết
3. Cập nhật P và Q bằng **gradient descent**

Ưu điểm:

- Dễ cài đặt
- Phù hợp với dữ liệu lớn

- Được dùng nhiều trong thực tế

6.3 ALS (Alternating Least Squares)

ALS là phương pháp tối ưu hóa khác cho Matrix Factorization.

Ý tưởng của ALS:

- Giữ **ma trận item (Q)** cố định → tính **ma trận user (P)**
- Sau đó giữ **P cố định** → tính **Q**
- Lặp lại quá trình này cho đến khi hội tụ.

Quy trình:

1. Khởi tạo ngẫu nhiên P và Q
2. Cố định Q → giải bài toán least squares để tìm P
3. Cố định P → giải bài toán least squares để tìm Q
4. Lặp lại cho đến khi sai số nhỏ.

Ưu điểm:

- Tính toán ổn định
- Phù hợp với hệ thống lớn
- Được sử dụng nhiều trong **Apache Spark MLlib**

IV. Các chỉ số đánh giá hệ thống

1. RMSE (Root Mean Squared Error)

RMSE là chỉ số đo **mức độ sai lệch giữa rating dự đoán và rating thực tế**. Chỉ số này thường được sử dụng trong **bài toán dự đoán rating (Prediction problem)**.

Công thức:

$$RMSE = \sqrt{\frac{1}{N}\sum_{(u,i)}(r_{ui} - \hat{r}_{ui})^2}$$

Trong đó:

- r_{ui}: rating thực tế của user *u* cho item *i*
- $\hat{r}_{ui}$: rating dự đoán

- N: số lượng rating trong tập test

Ý nghĩa:

- **RMSE càng nhỏ → mô hình càng chính xác**
- Được sử dụng rất phổ biến trong các bài toán dự đoán rating.

Ví dụ:

User	Movie	Rating thật	Rating dự đoán
U1	M1	5	4.8
U2	M2	3	3.2

RMSE sẽ đo **độ sai lệch trung bình** giữa các giá trị này.

2. Precision@K

Precision@K đánh giá **độ chính xác của danh sách gợi ý Top-K**.

Công thức:

$$Precision@K = \frac{\text{Số item phù hợp trong Top - K}}{K}$$

Ví dụ:

Hệ thống gợi ý **Top 5 phim** cho người dùng:

[Movie1, Movie2, Movie3, Movie4, Movie5]

Trong đó người dùng thực sự thích:

Movie2, Movie5

Ta có:

Precision@5 = 2 / 5 = 0.4

Ý nghĩa:

- Precision cao → danh sách gợi ý **chính xác hơn**.

3. Recall@K

Recall@K đo **khả năng hệ thống tìm được các item mà user thực sự thích**.

Công thức:

$$Recall@K = \frac{\text{Số item phù hợp trong Top - K}}{\text{Tổng số item phù hợp}}$$

Ví dụ:

User thực sự thích **4 phim**:

Movie2, Movie5, Movie8, Movie10

Hệ thống gợi ý Top 5:

Movie1, Movie2, Movie3, Movie4, Movie5

Trong đó đúng:

Movie2, Movie5

Ta có:

Recall@5 = 2 / 4 = 0.5

Ý nghĩa:

- Recall cao → hệ thống **không bỏ sót nhiều item tốt**.

V. Tổng kết

Trong đề tài này, hệ thống gợi ý được xây dựng dựa trên **Collaborative Filtering** kết hợp với **Matrix Factorization** nhằm dự đoán sở thích của người dùng và đề xuất các sản phẩm phù hợp.

Cụ thể, bài toán sử dụng **Collaborative Filtering theo hướng Model-Based**. Phương pháp này xây dựng một mô hình học máy từ dữ liệu đánh giá của người dùng thay vì chỉ dựa vào các phép đo tương tự đơn giản như trong Memory-Based methods.

Để học được mô hình từ dữ liệu, phương pháp **Matrix Factorization** được sử dụng nhằm phân rã ma trận **User–Item** thành các **đặc trưng tiềm ẩn (latent factors)** của người dùng và sản phẩm. Các đặc trưng tiềm ẩn này giúp mô hình khám phá mối quan hệ ẩn giữa người dùng và item, từ đó có thể dự đoán các rating còn thiếu.

Trong đề tài, thuật toán **Singular Value Decomposition (SVD)** được áp dụng để thực hiện quá trình phân rã ma trận. Thuật toán này giúp tìm ra các vector đặc trưng của user và item, từ đó dự đoán rating thông qua phép nhân giữa các vector latent factors.

Việc lựa chọn **Matrix Factorization với SVD** là phù hợp vì:

- Dữ liệu MovieLens có dạng **ma trận User–Item rất thưa (sparse)**
- Matrix Factorization có khả năng **khai thác các đặc trưng tiềm ẩn của dữ liệu**
- Phương pháp này đã chứng minh hiệu quả cao trong nhiều hệ thống gợi ý thực tế như **Netflix Recommendation System**

Sau khi huấn luyện mô hình, hiệu quả của hệ thống được đánh giá thông qua các chỉ số **RMSE, Precision@K và Recall@K**, nhằm đo lường độ chính xác của dự đoán và chất lượng của danh sách gợi ý.