

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG



THỰC TẬP CƠ SỞ

Weekly Report

Đề tài: XÂY DỰNG HỆ THỐNG GỌI Ý SẢN PHẨM

Giảng viên	: Kim Ngọc Bách
Họ và tên sinh viên	: Nguyễn Văn Trường
Mã sinh viên	: B23DCCN870
Lớp	: D23CQCN02-B
Nhóm	: 11

Hà Nội – 2026

Nội dung

2. LÝ THUYẾT USER-BASED COLLABORATIVE FILTERING	3
2.1. Khái niệm Cơ bản	3
2.2. Quy trình Hoạt động	3
2.3. Công thức Toán học	3
2.3.1. Độ tương đồng Cosine	3
2.3.2. Mean-Centered Ratings	3
2.3.3. Công thức Dự đoán Rating	4
3. TRIỂN KHAI CODE CHI TIẾT	4
3.2. Tính Ma trận Tương đồng	4
3.2.1. Mean-Centering (Vectorized)	4
3.2.2. Tính Cosine Similarity bằng Ma trận	4
3.3. Hàm Dự đoán (UBCF Predict)	4
4. ĐÁNH GIÁ MÔ HÌNH	5
4.1. Metrics Kết quả (K=30)	5
4.2. Tối ưu siêu tham số (K-Tuning)	5
5. CẢI TIẾN VÀ MỞ RỘNG	5
5.1. Các phương pháp Similarity khác	5
5.2. Kỹ thuật Tối ưu	6
6. KẾT LUẬN	6
6.1. Tóm tắt Kết quả	6
6.2. Đánh giá	7

2. LÝ THUYẾT USER-BASED COLLABORATIVE FILTERING

2.1. Khái niệm Cơ bản

Collaborative Filtering (CF) là phương pháp gợi ý dựa trên hành vi và sở thích của các người dùng tương tự. Nguyên lý cốt lõi của **User-Based CF** là: *"Những người có sở thích tương đồng trong quá khứ thường sẽ có xu hướng thích những thứ giống nhau trong tương lai."*

2.2. Quy trình Hoạt động

1. **Xây dựng ma trận User-Item (R):** Chuyển dữ liệu thô thành dạng bảng.
2. **Tính độ tương đồng:** Đo lường khoảng cách/góc giữa các profile người dùng.
3. **Tìm K hàng xóm gần nhất (KNN):** Chọn ra nhóm người dùng giống nhất với người dùng mục tiêu.
4. **Dự đoán rating:** Ước tính số sao dựa trên điểm số của nhóm hàng xóm.
5. **Đề xuất:** Gợi ý các item có rating dự đoán cao nhất mà người dùng chưa xem.

2.3. Công thức Toán học

2.3.1. Độ tương đồng Cosine

Đo lường góc giữa hai vector rating r_u và r_v :

$$\text{sim}(u, v) = \cos(\theta) = \frac{\sum(r_{ui} \times r_{vi})}{\sqrt{\sum r_{ui}^2} \times \sqrt{\sum r_{vi}^2}}$$

- **Giá trị [1]:** Hoàn toàn giống nhau.
- **Giá trị [0]:** Không liên quan.
- **Giá trị [-1]:** Hoàn toàn trái ngược.

2.3.2. Mean-Centered Ratings

Để loại bỏ thiên kiến (bias) cá nhân (người dùng khó tính thường chấm điểm thấp và ngược lại), ta chuẩn hóa dữ liệu:

$$r'_{ui} = r_{ui} - \bar{r}_u$$

Trong đó $\bar{r}_u$ là trung bình rating của người dùng u .

2.3.3. Công thức Dự đoán Rating

Dự đoán rating của người dùng u cho phim i :

$$\hat{r}_{ui} = \bar{r}_u + \frac{\sum_{v \in N(u)} \text{sim}(u, v) \times (r_{vi} - \bar{r}_v)}{\sum_{v \in N(u)} |\text{sim}(u, v)|}$$

- $N(u)$: Tập hợp K hàng xóm của u .
- **Ý nghĩa:** Kết quả là sự điều chỉnh từ mức trung bình của chính người dùng đó dựa trên ý kiến của những người có chung sở thích.

3. TRIỂN KHAI CODE CHI TIẾT

3.2. Tính Ma trận Tương đồng

3.2.1. Mean-Centering (Vectorized)

```
user_means = np.true_divide(R_train.sum(axis=1), (R_train != 0).sum(axis=1)).clip(min=1)
mask = (R_train != 0).astype(np.float32)
R_centered = (R_train - user_means[:, None]) * mask
```

3.2.2. Tính Cosine Similarity bằng Ma trận

```
norms = np.linalg.norm(R_centered, axis=1, keepdims=True).clip(min=1e-9)
R_norm = R_centered / norms
sim_user = R_norm @ R_norm.T
np.fill_diagonal(sim_user, 0)
```

3.3. Hàm Dự đoán (UBCF Predict)

```
def ubcf_predict(user_idx, movie_idx, K=30):
    sims = sim_user[user_idx].copy()
    rated_mask = R_train[:, movie_idx] > 0
    sims[~rated_mask] = 0

    top_k_idx = np.argsort(sims)[::-1][:K]
    top_k_sim = sims[top_k_idx]

    pos_mask = top_k_sim > 0
    if not pos_mask.any(): return user_means[user_idx]
```

```

top_k_idx, top_k_sim = top_k_idx[pos_mask], top_k_sim[pos_mask]
neighbor_ratings = R_train[top_k_idx, movie_idx]
neighbor_means = user_means[top_k_idx]

pred = user_means[user_idx] + np.dot(top_k_sim, neighbor_ratings -
neighbor_means) / top_k_sim.sum()
return float(np.clip(pred, 1.0, 5.0))

```

4. ĐÁNH GIÁ MÔ HÌNH

4.1. Metrics Kết quả (K=30)

- **MAE: 0.7746**
- **RMSE: 0.9863**
- **Coverage: 99.6%**

4.2. Tối ưu siêu tham số (K-Tuning)

- $K = 5$: RMSE = 1.0110
- $K = 30$: RMSE = **0.9859** (Tối ưu)
- $K = 100$: RMSE = 0.9883

5. CẢI TIẾN VÀ MỞ RỘNG

5.1. Các phương pháp Similarity khác

- **Pearson Correlation:**

$$\text{sim}(u, v) = \frac{\sum (r_{ui} - \bar{r}_u)(r_{vi} - \bar{r}_v)}{\sqrt{\sum (r_{ui} - \bar{r}_u)^2} \sqrt{\sum (r_{vi} - \bar{r}_v)^2}}$$

- Xét cả hướng và độ lớn của rating.
- Hoạt động tốt hơn Cosine khi người dùng có bias chấm điểm cực đoan (luôn quá cao hoặc quá thấp).

- **Jaccard Similarity:**

$$\text{sim}(u, v) = \frac{|I_u \cap I_v|}{|I_u \cup I_v|}$$

- Chỉ xét trên tập hợp các item chung mà hai user cùng tương tác.
- Đơn giản, tính toán nhanh nhưng bỏ qua giá trị cụ thể của rating.

5.2. Kỹ thuật Tối ưu

- **Approximate Nearest Neighbors (ANN):**

- Sử dụng các thuật toán như LSH (Locality Sensitive Hashing) để tìm hàng xóm.
- Giảm độ phức tạp từ $O(n^2)$ xuống còn $O(n \log n)$, cực kỳ quan trọng cho dữ liệu lớn.

- **Matrix Factorization:**

- Sử dụng SVD (Singular Value Decomposition) hoặc NMF để nén ma trận thưa thành các không gian ẩn (latent factors).
- Giúp giảm chiều dữ liệu và tăng tốc độ dự đoán.

- **Hybrid Methods:**

- Kết hợp giữa User-based và Item-based để tận dụng ưu điểm của cả hai.
- Kết hợp Collaborative Filtering với Content-based (dựa trên thông tin thể loại, đạo diễn) để giải quyết bài toán Cold Start.

6. KẾT LUẬN

6.1. Tóm tắt Kết quả

- **Mô hình:** User-Based Collaborative Filtering.
- **Dataset:** MovieLens 100K (943 users, 1682 movies, 100K ratings).
- **Hiệu suất:** Đạt MAE = 0.7746 và RMSE = 0.9863 với độ phủ 99.6%.
- **Tham số tối ưu:** $K = 30$ hàng xóm cho kết quả cân bằng nhất giữa tín hiệu và nhiễu.

6.2. Đánh giá

User-Based CF là phương pháp nền tảng, hiệu quả và dễ triển khai cho các hệ thống gợi ý.

- **Phù hợp với:**

- Hệ thống có quy mô người dùng nhỏ hoặc trung bình (< 100.000 users).
- Ứng dụng cần khả năng giải thích gợi ý rõ ràng.
- Khi sở thích của người dùng thay đổi nhanh chóng (hệ thống cập nhật theo hành vi hàng xóm mới).

- **Không phù hợp với:**

- Hệ thống khổng lồ (hàng triệu users) do chi phí tính toán ma trận tương đồng quá lớn.
- Trường hợp có quá nhiều người dùng mới hoặc phim mới (Cold Start).
- Yêu cầu phản hồi thời gian thực (Real-time) trên dữ liệu thô mà không qua tiền xử lý/nén dữ liệu.