HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

THỰC TẬP CƠ SỞ

Weekly Report

Đề tài: XÂY DỰNG HỆ THỐNG GỢI Ý SẢN PHẨM

Giai đoạn 2.1: Phân tích dữ liệu

Giảng viên	**: Kim Ngọc Bách**
Họ và tên sinh viên	**: Nguyễn Văn Trường**
Mã sinh viên	**: B23DCCN870**
Lớp	**: D23CQCN02-B**
Nhóm	**: 11**

Hà Nội – 2026

Nội dung

I. Khám phá dữ liệu - EDA 3
1. Thống kê tổng quan: 3
2. Ratings 3
3. Movies 5
II. Xây dựng ma trận user – items 8
Phụ lục 9
Vẽ biểu đồ phân phối ratings 9
Vẽ biểu đồ ratings/ user 11
Vẽ biểu đồ top 10 phim 11
Vẽ biểu đồ Ratings/ movies 12
Vẽ biểu đồ users - items 13

I. Khám phá dữ liệu - EDA

Phân tích EDA là một trong những bước quan trọng trong quá trình xây dựng hệ thống gợi ý sản phẩm.

Trước khi xây dựng mô hình, bạn cần xây dựng các đặc trưng. Trước khi xây dựng đặc trưng, bạn phải làm bước khai phá dữ liệu

Bước EDA này giúp chúng ta có cái nhìn đầu tiên về dữ liệu: hiểu rõ đặc điểm, cấu trúc, chất lượng của tập dữ liệu trước khi tiến hành xây dựng mô hình.

1. Thống kê tổng quan:

```
THỐNG KÊ TỔNG QUAN
  Số lượng users       : 943
  Số lượng movies      : 1,682
  Số lượng ratings     : 100,000
  Rating (min/max/avg) : 1 / 5 / 3.53
  Kích thước ma trận   : 943 x 1682 = 1,586,126 ô
  Sparsity             : 93.70%
```

2. Ratings

Dưới đây là 10 dòng đầu tiên của dataframe rating. Dữ liệu gồm thông tin về mã người dùng (UserID), mã phim (MovieID), đánh giá trong thang điểm 5, và thời điểm đánh giá Timestamp.

	userId	movieId	rating	timestamp
0	196	242	3	881250949
1	186	302	3	891717742
2	22	377	1	878887116
3	244	51	2	880606923
4	166	346	1	886397596
5	298	474	4	884182806
6	115	265	2	881171488
7	253	465	5	891628467
8	305	451	3	886324817
9	6	86	3	883603013

```
Phân phối Rating:
```

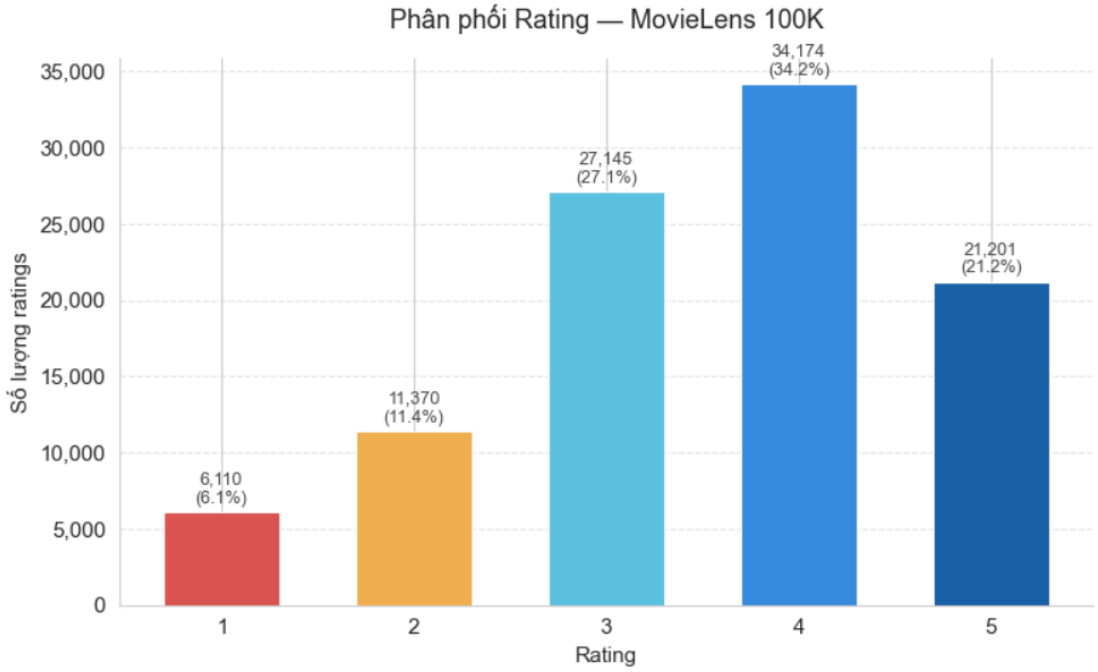

Phân phối của các điểm đánh giá trong biểu đồ trên cho thấy rằng số lượng điểm 4 được đánh giá nhiều nhất chiếm 34,2 % trong khi các điểm 1, 2 có ít lượng đánh giá nhất chỉ chiếm lần lượt là 6,1 % và 11,4%. Điều này cho ta thấy người dùng có hành vi thường đánh giá khi họ rất thích một bộ phim; khi họ không thực sự thích họ sẽ ít ra đánh giá hơn.

```
Thống kê số rating / User:
──────────────────────────────────────
Min      : 20
Max      : 737
Mean     : 106.0
Median   : 65.0
Std      : 100.9
```

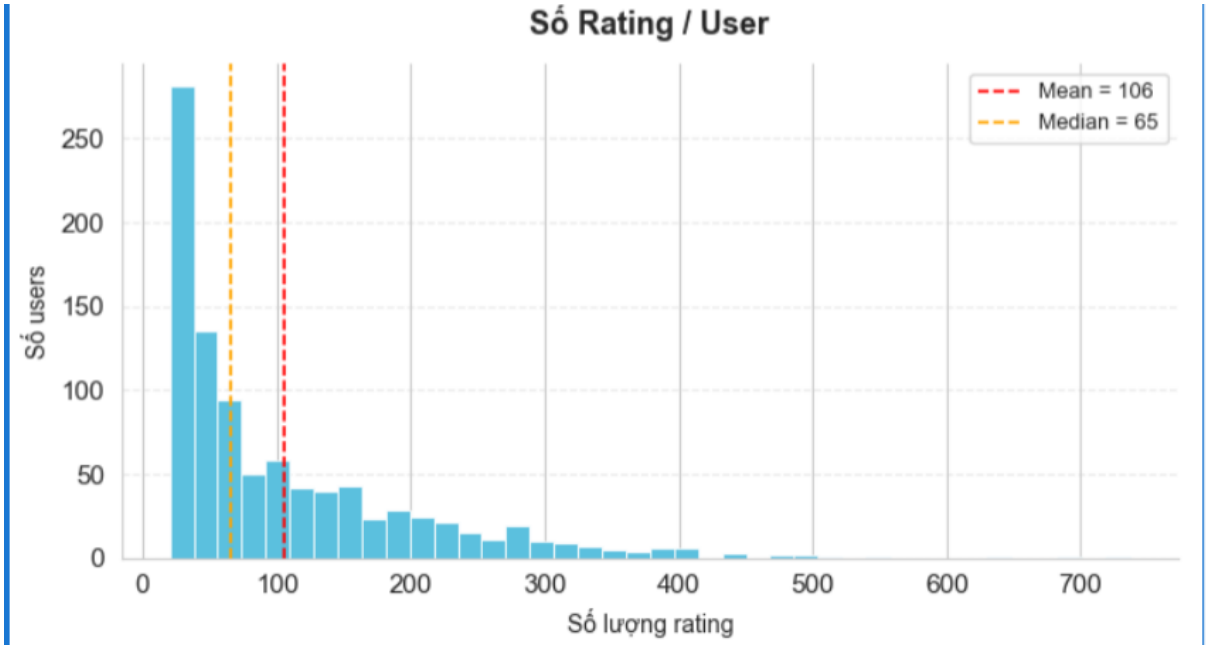

Ta thấy rằng 20 là số lượng đánh giá ít nhất mà người dùng đưa ra trong khi tối đa lên tới 737. Điều này thấy bộ dữ liệu đã được tiền xử lý nhằm loại bỏ các người dùng có ít tương tác.

Việc mỗi người dùng có số lượng đánh giá tương đối lớn giúp tăng độ tin cậy của dữ liệu, từ đó cải thiện khả năng học của mô hình. Cụ thể, trong các phương pháp Collaborative Filtering, số lượng tương tác càng nhiều thì việc xác định độ tương đồng giữa các người dùng hoặc các item càng chính xác, dẫn đến chất lượng gợi ý được nâng cao.

Giá trị trung bình 106 lớn hơn trung vị 65 cho thấy rằng số lượng rating trên mỗi người dùng có xu hướng lệch phải. Điều này phản ánh rằng phần lớn người dùng chỉ thực hiện một số lượng đánh giá ở mức trung bình, trong khi đó tồn tại một số ít người dùng có mức độ hoạt động rất cao, làm tăng giá trị trung bình của toàn tập dữ liệu.

Bên cạnh đó, độ lệch chuẩn (100,9) cho thấy mức độ phân tán của dữ liệu cao, thể hiện sự khác biệt đáng kể trong hành vi giữa các người dùng.

3. Movies

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1682 entries, 0 to 1681
Data columns (total 24 columns):
 #   Column              Non-Null Count  Dtype
---  ------              --------------  -----
 0   movieId             1682 non-null   int64
 1   title               1682 non-null   object
 2   release_date        1681 non-null   object
 3   video_release_date  0 non-null      float64
 4   imdb_url            1679 non-null   object
 5   unknown             1682 non-null   int64
 6   Action              1682 non-null   int64
 7   Adventure           1682 non-null   int64
 8   Animation           1682 non-null   int64
 9   Childrens           1682 non-null   int64
 10  Comedy              1682 non-null   int64
 11  Crime               1682 non-null   int64
 12  Documentary         1682 non-null   int64
 13  Drama               1682 non-null   int64
 14  Fantasy             1682 non-null   int64
 15  Film_Noir           1682 non-null   int64
 16  Horror              1682 non-null   int64
 17  Musical             1682 non-null   int64
 18  Mystery             1682 non-null   int64
 19  Romance             1682 non-null   int64
 20  Sci_Fi              1682 non-null   int64
 21  Thriller            1682 non-null   int64
 22  War                 1682 non-null   int64
 23  Western             1682 non-null   int64
dtypes: float64(1), int64(20), object(3)
memory usage: 315.5+ KB
None
```

Bảng dữ liệu phim gồm 1682 bản ghi với 24 thuộc tính, bao gồm các thông tin về tiêu đề, ngày phát hành và các thể loại phim. Các thể loại được biểu diễn dưới dạng one-hot encoding, với giá trị 0 hoặc 1 tương ứng với việc phim có thuộc thể loại đó hay không.

Qua kiểm tra, một số thuộc tính có giá trị thiếu. Đáng chú ý, cột video_release_date không chứa bất kỳ giá trị nào (0 non-null), do đó không mang thông tin hữu ích và được loại bỏ trong quá trình tiền xử lý.

Các thuộc tính còn lại chỉ thiếu mộ số lượng rất nhỏ giá trị so với tổng thể dữ liệu, nên không ảnh hưởng đáng kể đến chất lượng và có thể được giữ nguyên.

Dưới đây là 10 dòng đầu của dataframe movies và top 10 bộ phim được đánh giá nhiều nhất:

	movieId	title	release_date	video_release_date	imdb_url	unknown	Action	Adventure	Animation	Childrens	...
0	1	Toy Story (1995)	01-Jan-1995	NaN	http://us.imdb.com/M/title-exact?Toy%20Story%2...	0	0	0	1	1	...
1	2	GoldenEye (1995)	01-Jan-1995	NaN	http://us.imdb.com/M/title-exact?GoldenEye%20(...	0	1	1	0	0	...
2	3	Four Rooms (1995)	01-Jan-1995	NaN	http://us.imdb.com/M/title-exact?Four%20Rooms%...	0	0	0	0	0	...
3	4	Get Shorty (1995)	01-Jan-1995	NaN	http://us.imdb.com/M/title-exact?Get%20Shorty%...	0	1	0	0	0	...
4	5	Copycat (1995)	01-Jan-1995	NaN	http://us.imdb.com/M/title-exact?Copycat%20(1995)	0	0	0	0	0	...
5	6	Shanghai Triad (Yao a yao yao dao waipo qiao) ...	01-Jan-1995	NaN	http://us.imdb.com/Title?Yao+a+yao+yao+dao+wai...	0	0	0	0	0	...
6	7	Twelve Monkeys (1995)	01-Jan-1995	NaN	http://us.imdb.com/M/title-exact?Twelve%20Monk...	0	0	0	0	0	...
7	8	Babe (1995)	01-Jan-1995	NaN	http://us.imdb.com/M/title-exact?Babe%20(1995)	0	0	0	0	1	...
8	9	Dead Man Walking (1995)	01-Jan-1995	NaN	http://us.imdb.com/M/title-exact?Dead%20Man%20...	0	0	0	0	0	...
9	10	Richard III (1995)	22-Jan-1996	NaN	http://us.imdb.com/M/title-exact?Richard%20III...	0	0	0	0	0	...

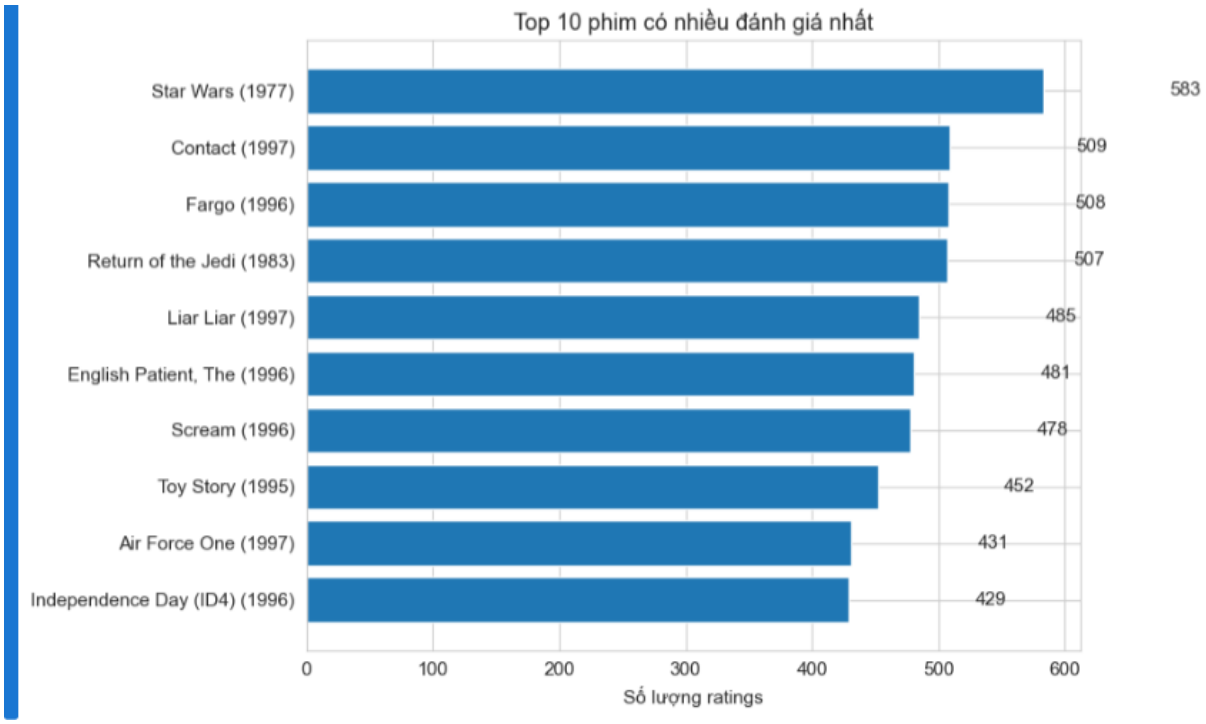

```
Thống kê số rating / Movie:
──────────────────────────────────────
Min      : 1
Max      : 583
Mean     : 59.5
Median   : 27.0
Std      : 80.4
```

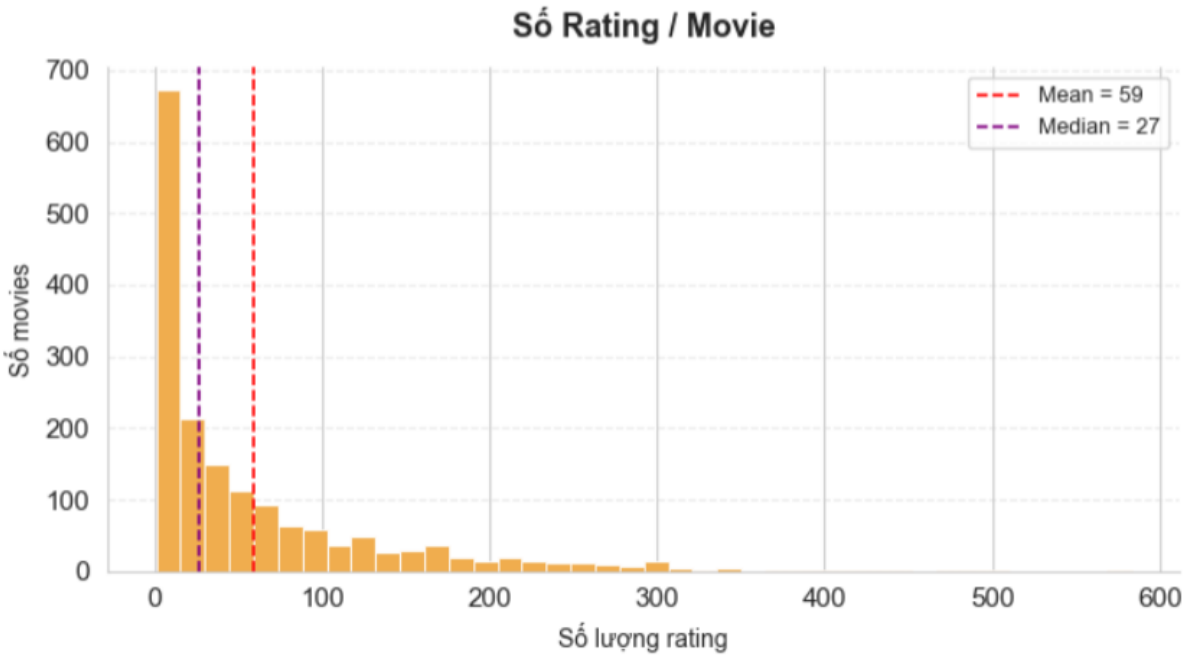

Thống kê số lượng rating trên bộ phim cho thấy sự chênh lệch đáng kể giữa các item trong tập dữ liệu. Cụ thể, số lượng rating tối thiểu là 1, trong khi tối đa lên tới 583. Điều này cho thấy tồn tại nhiều bộ phim rất ít được đánh giá trong khi, trong khi một số bộ phim khác lại thu hút lượng lớn người dùng.

Giá trị trung bình (59,5) lớn hơn trung vị (27) cho thấy phân bố dữ liệu bị lệch phải, phản ánh sự tồn tại của một số bộ phim rất phổ biến với số lượng rating cao, trong khi các phần lớn các bộ phim còn lại có mức độ tương tác thấp.

Bên cạnh đó, độ lệch chuẩn lớn(80,4) cho thấy mức độ phân tán cao, thể hiện sự không đồng đều rõ rệt về mức độ phổ biến giữa các bộ phim.

II. Xây dựng ma trận user – items

Ma trận user-item được xây dựng nhằm biểu diễn dữ liệu đánh giá ratings của người dùng đối với các sản phẩm dưới dạng ma trận số.

Trong ma trận này, mỗi hàng đại diện cho một người dùng (user) và mỗi cột đại diện cho một sản phẩm (item), và mỗi phần tử thể hiện mức độ đánh giá của người dùng đối với sản phẩm tương ứng.

Xây dựng ma trận:

```
Kích thước ma trận : 943 x 1682
Số ô có rating     : 100,000  (6.30%)
Số ô trống (NaN)   : 1,486,126  (93.70%)

Góc trên-trái (10 users x 10 movies):
movieId   1    2    3    4    5    6    7    8    9    10
userId
1        5.0  3.0  4.0  3.0  3.0  5.0  4.0  1.0  5.0  3.0
2        4.0  NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN  2.0
3        NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN
4        NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN
5        4.0  3.0  NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN
6        4.0  NaN  NaN  NaN  NaN  NaN  2.0  4.0  4.0  NaN
7        NaN  NaN  NaN  5.0  NaN  NaN  5.0  5.0  5.0  4.0
8        NaN  NaN  NaN  NaN  NaN  NaN  3.0  NaN  NaN  NaN
9        NaN  NaN  NaN  NaN  NaN  5.0  4.0  NaN  NaN  NaN
10       4.0  NaN  NaN  4.0  NaN  NaN  4.0  NaN  4.0  NaN
```

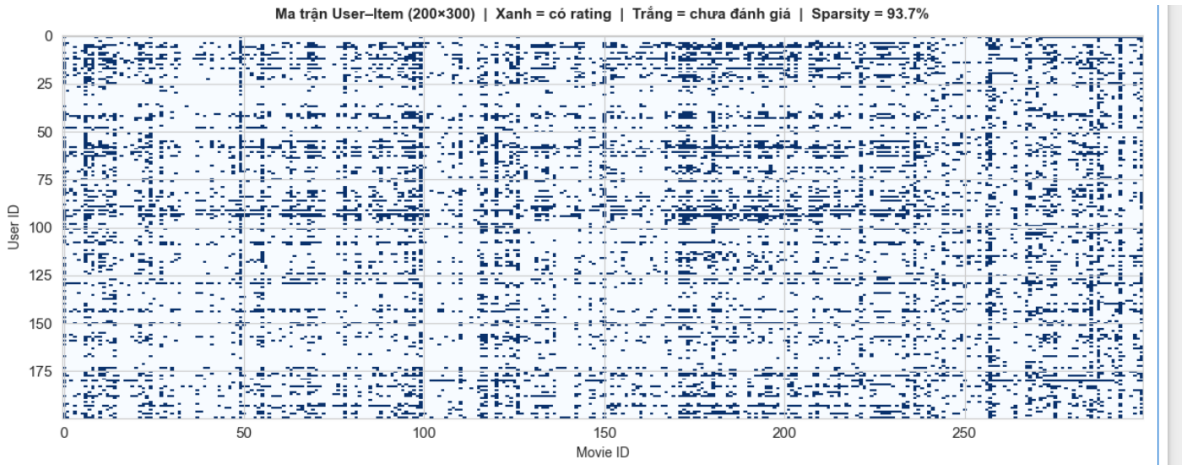

Phụ lục

Vẽ biểu đồ phân phối ratings

print(f"\n Phân phối Rating: \n")

rating_counts = df_ratings['rating'].value_counts().sort_index()

```
colors = ['#d9534f', '#f0ad4e', '#5bc0de', '#378ADD', '#185FA5']

fig, ax = plt.subplots(figsize=(8, 5))

bars = ax.bar(rating_counts.index, rating_counts.values,
              color=colors, width=0.6, edgecolor='white', linewidth=0.8)

total = rating_counts.sum()
for bar, count in zip(bars, rating_counts.values):
    pct = count / total * 100
    ax.text(bar.get_x() + bar.get_width() / 2, bar.get_height() + 300,
            f'{count:,}\n({pct:.1f}%)', ha='center', va='bottom', fontsize=9, color='#444')

ax.set_xlabel('Rating')
ax.set_ylabel('Số lượng ratings')
ax.set_title('Phân phối Rating — MovieLens 100K', pad = "15")
ax.set_xticks([1, 2, 3, 4, 5])
ax.yaxis.set_major_formatter(plt.FuncFormatter(lambda x, _: f'{int(x):,}'))
ax.spines[['top', 'right']].set_visible(False)
ax.set_axisbelow(True)
ax.yaxis.grid(True, linestyle='--', alpha=0.5)

plt.tight_layout()
plt.show()
```

Vẽ biểu đồ Ratings/ user

```
fig, ax = plt.subplots(figsize=(7, 4))

ax.hist(user_counts, bins=40, color="#5bc0de", edgecolor="white", linewidth=0.6)
ax.axvline(user_counts.mean(), color="red", linestyle="--", linewidth=1.2,
```

```
        label=f"Mean = {user_counts.mean():.0f}")
ax.axvline(user_counts.median(), color="orange", linestyle="--", linewidth=1.2,
        label=f"Median = {user_counts.median():.0f}")
```

Vẽ biểu đồ ratings/ user

```
ax.set_title("Số Rating / User", fontsize=13, fontweight="bold", pad=12)
ax.set_xlabel("Số lượng rating", fontsize=10)
ax.set_ylabel("Số users", fontsize=10)
ax.yaxis.set_major_formatter(plt.FuncFormatter(lambda x, _: f"{int(x):,}"))
ax.spines[["top", "right"]].set_visible(False)
ax.yaxis.grid(True, linestyle="--", alpha=0.4)
ax.set_axisbelow(True)
ax.legend(fontsize=9)

plt.tight_layout()
plt.savefig(os.path.join(OUTPUT_DIR, "02_ratings_per_user.png"), dpi=150,
bbox_inches="tight")
plt.show()
```

Vẽ biểu đồ top 10 phim

```
plt.figure(figsize=(10, 6))

bars = plt.barh(labels, values, color='#378ADD')

plt.gca().invert_yaxis()

for bar in bars:
    width = bar.get_width()
    plt.text(width + 100, bar.get_y() + bar.get_height()/2,
            f'{int(width):,}', va='center', fontsize=9)
```

```
plt.xlabel('Số lượng ratings')
plt.title('Top 10 phim có nhiều đánh giá nhất')

plt.grid(axis='x', linestyle='--', alpha=0.5)

plt.tight_layout()
plt.show()
```

Vẽ biểu đồ Ratings/ movies

```
fig, ax = plt.subplots(figsize=(7, 4))

ax.hist(movie_counts, bins=40, color="#f0ad4e", edgecolor="white", linewidth=0.6)
ax.axvline(movie_counts.mean(), color="red", linestyle="--", linewidth=1.2,
        label=f"Mean = {movie_counts.mean():.0f}")
ax.axvline(movie_counts.median(), color="purple", linestyle="--", linewidth=1.2,
        label=f"Median = {movie_counts.median():.0f}")

ax.set_title("Số Rating / Movie", fontsize=13, fontweight="bold", pad=12)
ax.set_xlabel("Số lượng rating", fontsize=10)
ax.set_ylabel("Số movies", fontsize=10)
ax.yaxis.set_major_formatter(plt.FuncFormatter(lambda x, _: f"{int(x):,}"))
ax.spines[["top", "right"]].set_visible(False)
ax.yaxis.grid(True, linestyle="--", alpha=0.4)
ax.set_axisbelow(True)
ax.legend(fontsize=9)

plt.tight_layout()
plt.savefig(os.path.join(OUTPUT_DIR, "03_ratings_per_movie.png"), dpi=150,
bbox_inches="tight")
plt.show()
```

Vẽ biểu đồ users - items

```
fig, ax = plt.subplots(figsize=(12, 5))


sample = user_item_matrix.iloc[:200, :300].notna().astype(int)

ax.imshow(sample, aspect="auto", cmap="Blues", interpolation="none")


ax.set_title(

    f"Ma trận User–Item (200×300) | Xanh = có rating | Trắng = chưa đánh giá | Sparsity = {sparsity*100:.1f}%",

    fontsize=11, fontweight="bold", pad=12)

ax.set_xlabel("Movie ID", fontsize=10)

ax.set_ylabel("User ID", fontsize=10)



plt.tight_layout()

plt.savefig(os.path.join(OUTPUT_DIR, "05_matrix_sparsity.png"), dpi=150, bbox_inches="tight")

plt.show()
```